News-Based Stock Market Prediction

Prédiction de la direction du Dow Jones Industrial Average à partir de titres Reddit (2008-2016)

Équipe : Akram Boudebouze · Alexander Besson · Ferdinand Carsoux · Raphaël Essengue

Professeurs : M. El Fakir & N. de Roux

Dataset : Kaggle · 2008-2016 · 1 989 jours de bourse · 25 titres/jour

Plan de la présentation

01

Données & Exploration

Dataset Reddit/DJIA — 8 ans, 1 989 jours, 25 titres/jour

02

Feature Engineering

TF-IDF · Features financières (yfinance) · Sentiment VADER

03

Modélisation

3 niveaux : Classiques → Word2Vec → FinBERT

04

Résultats & Conclusion

Interprétation, limites et perspectives

1 - Données & Exploration

1989

Jours de bourse

2008 → 2016

25

Titres Reddit/jour

Top 1 → Top 25

53.5%

Jours en hausse

Dataset quasi-équilibré

8

Années de données

Crise 2008 incluse

Structure du dataset

Date: Jour de trading

Label (0/1): Baisse/Hausse

Top1 à Top25: Titres Reddit

Observations clés

- 📈 Crise 2008–2009 visible : DJIA 12k → 6.5k
- 🗞️ Mots dominants : police, china, government → géopolitique
- 📝 ~500 mots/jour : 25 titres × ~20 mots

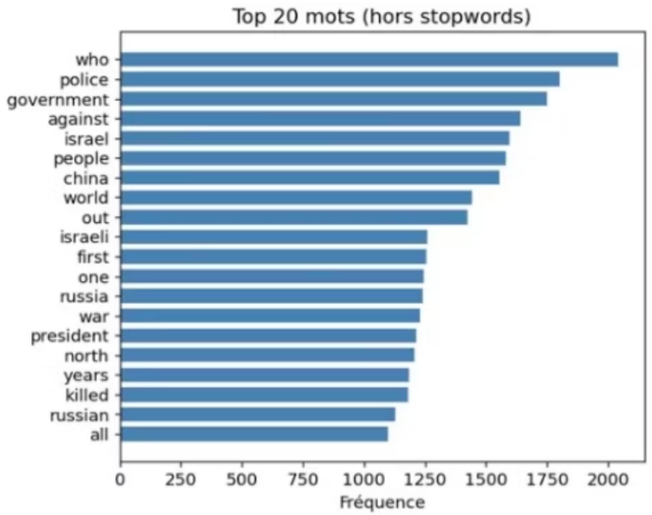

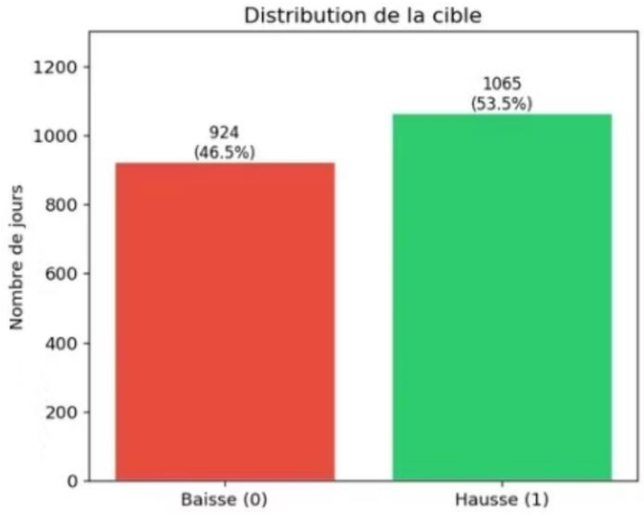

ℹ **Bug fix V1→V2 :** Préfixe b'...' (Python 2 scraping) supprimé sur tous les titres → Impact : TF-IDF bigrammes corrects ("north korea", "stock market")

2 - Feature Engineering

Split chronologique strict : Train 2008→2013 (60%) · Validation 2014 (20%) · Test 2015→2016 (20%)

TF-IDF

- 5 000 features
- Bigrammes (1,2)
- sublinear_tf=True
- stop_words anglais

Financières

- 6 features
- ret_1d, ret_5d
- vol_5d, vol_20d
- RSI 14j · day_of_week

Sentiment VADER

- 4 features
- sent_pos, sent_neg
- sent_neu
- sent_compound

Corrélation features vs Label

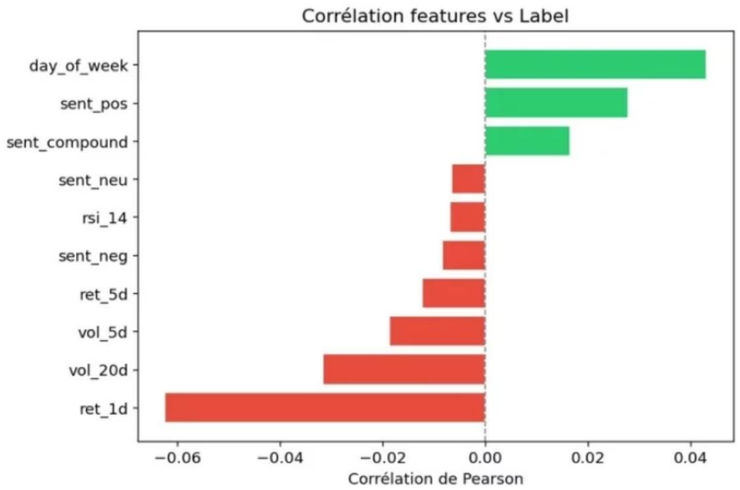

▼ X_all = TF-IDF + Financières + Sentiment → 5 010 dimensions

ⓘ 💡 **Insight :** day_of_week est la feature la plus corrélée positivement au label → effet calendrier sous-estimé. ret_1d montre une corrélation négative → signal de mean-reversion.

3 - Modélisation

Protocole : Walk-Forward Validation (3 fenêtres glissantes) · Métriques : Accuracy · F1 · AUC-ROC

Niveau 1 — Classiques

TF-IDF + Financières + Sentiment

- Logistique (C=1.0)
- Random Forest (200 arbres)
- Gradient Boosting

Meilleur : GB · AUC 0.537

Niveau 2 — Word2Vec

Word2Vec + Financières + Sentiment

- 200 dimensions
- Skip-gram, window=5
- Doc = moyenne vecteurs

Meilleur global · AUC 0.550

Niveau 3 — FinBERT

Embeddings contextuels

- ProsusAI/finbert (109M)
- Fine-tuning 3 époques
- MAX_LEN=256 tokens

AUC 0.482 — overfitting

Walk-Forward Validation

Fenêtre	Train	Test
1	2008 → 2011	2012
2	2008 → 2012	2013
3	2008 → 2013	2014

⚠ Contre-intuitif : Word2Vec (N2) > FinBERT (N3)

FinBERT souffre du corpus trop petit (255 steps seulement). Le F1 élevé (0.665) masque un biais vers la classe "hausse" . l'AUC (0.482) révèle une discrimination quasi-aléatoire.

4 - Résultats comparatifs

Niveau	Modèle	Accuracy	F1	AUC-ROC
N1 — Classique	Régression Logistique	0.487	0.592	0.481
N1 — Classique	Random Forest	0.508	0.652	0.481
N1 — Classique	Gradient Boosting	0.511	0.588	0.537
N2 — Embeddings	**Word2Vec + GB**	**0.534**	**0.627**	**0.550**
N3 — Transformer	FinBERT	0.503	0.665	0.482

🏆 **Meilleur modèle :** Word2Vec + GB (AUC 0.550, Accuracy 0.534)

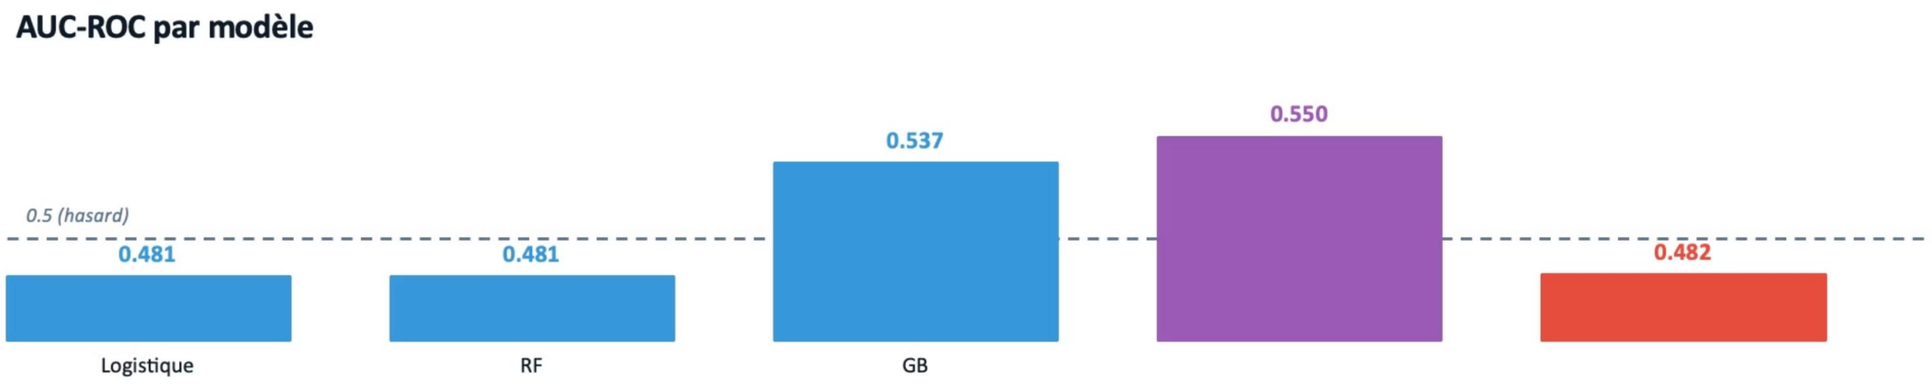

5 - Interprétation & Conclusion

Feature Importance (Gradient Boosting)

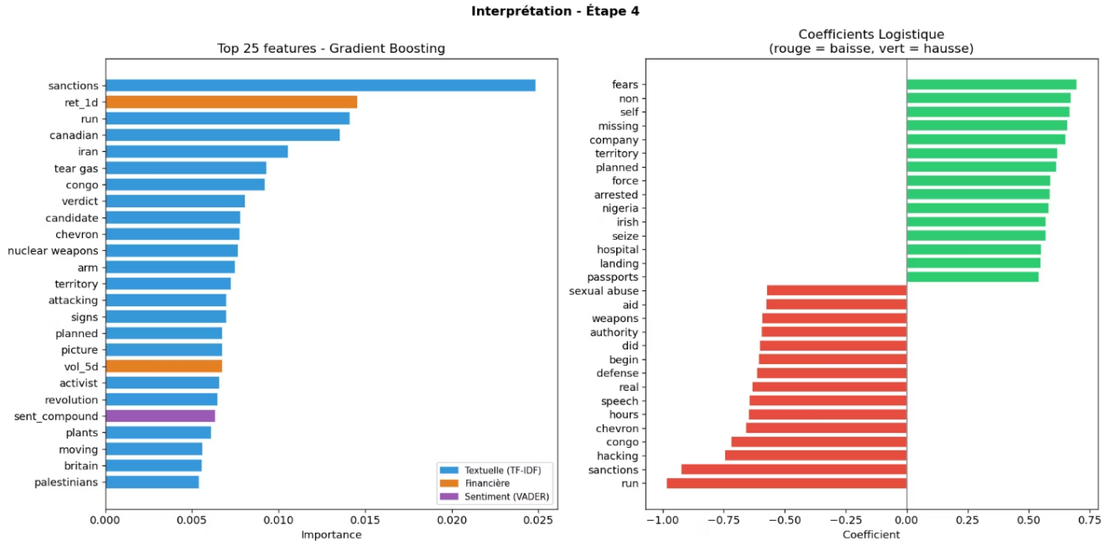

Limites & Perspectives

- **Biais vers la hausse**
- 280 pred. hausse vs 98 baisse → discrimine mal les baisses
- **2013 systématiquement < 0.5**
- Signal absent cette année quelle que soit la méthode
- **FinBERT : data hunger**
- 109M params, 255 steps → trop peu de données

Piste d'amélioration

Feature extraction figée, corpus plus grand, hyperopt

Conclusion : Le signal textuel est un proxy imparfait. Avec AUC ~0.55, les modèles font légèrement mieux que le hasard mais restent fragiles face à l'instabilité temporelle des marchés.

Merci !

Projet : News-Based DJIA Prediction · Dataset Kaggle 2008–2016 · 3 niveaux de modélisation

0.550	53.4%	1989
AUC	Accuracy	Jours
Word2Vec + GB	Meilleur modèle	Dataset